KNN classification-weights

In [1]:
```
import numpy as np
import pandas as pd
```

In [2]:
```
data = pd.read_csv(r"iris.csv")
# data.head() # 显示前5行
# data.tail() # 显示末尾5行
# data.sample()# 随机抽取某行
data.sample(10)# 随机抽取10行
data["Species"] = data["Species"].map({"versicolor":0,"setosa":1,"virginica":2})
data
```

Out[2]:

	Unnamed: 0	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
0	1	5.1	3.5	1.4	0.2	1
1	2	4.9	3.0	1.4	0.2	1
2	3	4.7	3.2	1.3	0.2	1
3	4	4.6	3.1	1.5	0.2	1
4	5	5.0	3.6	1.4	0.2	1
...	...	...	...	...	...	...
145	146	6.7	3.0	5.2	2.3	2
146	147	6.3	2.5	5.0	1.9	2
147	148	6.5	3.0	5.2	2.0	2
148	149	6.2	3.4	5.4	2.3	2
149	150	5.9	3.0	5.1	1.8	2

150 rows × 6 columns

In [3]:
```
data.drop("Unnamed: 0",axis=1,inplace=True)# 删除不需要的ID列,inplace=True即在原
# data.drop("Unnamed: 0",axis=1)会直接生成一个新的表data1,所以也可以data = data.d
data.duplicated().any()# 检查重复值;.any()返回True，表明有重复值
data.drop_duplicates(inplace=True)# 删除重复值
len(data) # 表格有多少条记录
# 查看各个类别的鸢尾花具有多少条记录
data["Species"].value_counts()
```

Out[3]:
```
Species
1    50
0    50
2    49
Name: count, dtype: int64
```

In [4]:
```
class KNN:
    """使用python语言实现K近邻算法（实现分类）"""
    def __init__(self,k):
        """初始化方法
        Parameters
        -----
```

```
        k:int
            邻居的个数。
        """
        self.k = k
    def fit(self,X,y):# 矩阵，大写，向量，小写
        """训练方法
        Parameters
        ------
        X:类数组类型(类似数组类型，如list,data.frame);形状为：{样本的数量149，特征
          待训练的样本特征（属性）
        y:类数组类型，形状为：{样本的数量149}
          每个样本的目标值（标签）
        """
        self.X = np.asarray(X)# 将X转换为ndarray数组形式,如果本身就是ndarray,则不
        self.y = np.asarray(y)
    def predict2(self,X):
        """
        根据参数传递的样本，对样本数据进行预测
        Parameters
        -----
        X:类数组类型，形状为：{样本数量，特征数量}
          待训练的样本特征（属性）
        Returns
        -----
        result:数组类型
            预测的结果
        """
        X = np.asarray(X)
        result = []
        for x in X:# 对ndarray数组进行遍历，每次取数组中的一行（对于测试集中的每一
            dis = np.sqrt(np.sum((x - self.X)**2,axis = 1)) #按行的方式求和，再开
            index = dis.argsort() #返回数组排序后，每个元素在排序之前的数组中的索
            # 进行截断，只取前k个元素（取距离最近的k个元素的索引）
            index = index[:self.k] #到self.k为止
            # 返回数组中每个元素出现的次数，元素必须是非负的整数
            count = np.bincount(self.y[index],weights=1 / dis[index]) # 使用距离
            # 返回ndarray数组中，值最大的元素对应的索引(即出现次数最多的元素)，该
            result.append(count.argmax())
        return np.asarray(result)
```

In [10]:

```
# 拆分数据集
# 提取出每个类别的鸢尾花数据
t0 = data[data["Species"] == 0]
t1 = data[data["Species"] == 1]
t2 = data[data["Species"] == 2]
# 打乱顺序,对每个类别数据进行洗牌
t0 = t0.sample(len(t0),random_state = 0) # random_state=类似于随机种子
t1 = t1.sample(len(t1),random_state = 0)
t2 = t2.sample(len(t2),random_state = 0)
# 构建训练集与测试集
train_X = pd.concat([t0.iloc[:40,:-1],t1.iloc[:40,:-1],t2.iloc[:40,:-1]],axis =
train_y = pd.concat([t0.iloc[:40,-1],t1.iloc[:40,-1],t2.iloc[:40,-1]],axis = 0)
test_X = pd.concat([t0.iloc[40:,:-1],t1.iloc[40:,:-1],t2.iloc[40:,:-1]],axis = 0
test_y = pd.concat([t0.iloc[40:,-1],t1.iloc[40:,-1],t2.iloc[40:,-1]],axis = 0)
# 创建KNN对象，进行训练与测试
knn = KNN(k = 3)
# 进行训练
knn.fit(train_X, train_y)
# 进行测试，获得测试的结果
result = knn.predict2(test_X)
```

```
# display(result)
# display(test_y)
# display(result == test_y)# 检测正确情况
display(np.sum(result == test_y))# True是1，False是0，可以用np.sum直接求和
display(len(result)) # 总的检测数据
display(np.sum(result == test_y)/len(result))# 预测正确比例
```

```
28
29
0.9655172413793104
```

In [11]:
```
# 考虑权重，进行测试
result2 = knn.predict2(test_X)
display(np.sum(result2 == test_y))# 此数据结果没有差异
```

```
28
```

In [12]:
```
# KNN可视化
import matplotlib as mpl
import matplotlib.pyplot as plt
```

In [13]:
```
# 默认情况下，matplotlib不支持中文显示，我们需要进行设置
mpl.rcParams["font.family"] = "SimHei"
# 在中文字体时，能够正常显示负号（-）
mpl.rcParams["axes.unicode_minus"] = False
```

In [14]:
```
# {"versicolor":0,"setosa":1,"virginica":2}
# 设置画布大小
plt.figure(figsize=(10,10))# 单位，英寸
# 绘制训练集数据
# Unnamed: 0    Sepal.Length    Sepal.Width    Petal.Length    Petal.Width
plt.scatter(x=t0["Sepal.Length"][:40], y=t0["Petal.Length"][:40], color="r", lab
plt.scatter(x=t1["Sepal.Length"][:40], y=t1["Petal.Length"][:40], color="g", lab
plt.scatter(x=t2["Sepal.Length"][:40], y=t2["Petal.Length"][:40], color="b", lab
# 绘制测试集数据
right = test_X[result == test_y]
wrong = test_X[result != test_y]
plt.scatter(x=right["Sepal.Length"],y=right["Petal.Length"],color="c",marker="x"
plt.scatter(x=wrong["Sepal.Length"],y=wrong["Petal.Length"],color="m",marker=">"
plt.xlabel("花萼长度")
plt.ylabel("花瓣长度")
plt.title("KNN分类结果显示")
plt.legend(loc="best")
plt.show()
```

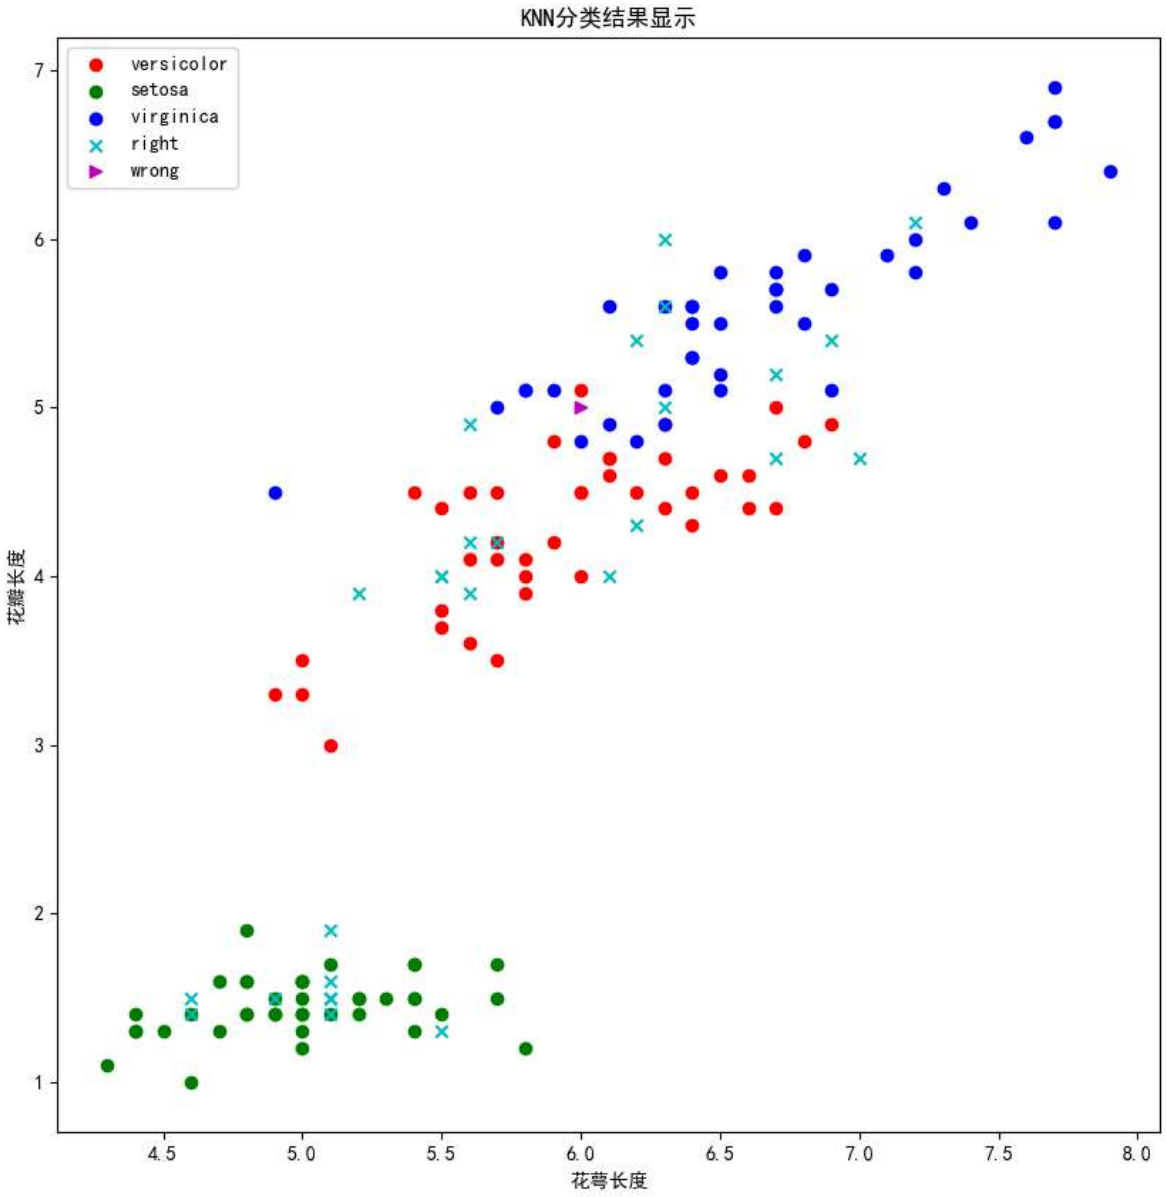
KNN分类结果显示
versicolor
setosa
virginica
right
wrong
花瓣长度
花萼长度
1
2
3
4
5
6
7
4.5
5.0
5.5
6.0
6.5
7.0
7.5
8.0